

AQ11

Algoritmus generovania pravidiel

Symbolické strojové učenie a interpretovateľná umelá inteligencia

Interaktívna webová aplikácia · Dataset 1 000 vzoriek · Porovnanie modelov
Experimenty · Vizualizácie · Konfúzna matica · Metriky výkonu

Predmet:

Strojové učenie

Akademický rok:

2025/2026

Vypracoval:

Matej Kortán

Abstrakt

Táto práca sa zaoberá podrobnou analýzou, implementáciou a experimentálnym hodnotením algoritmu AQ11, ktorý patrí do rodiny algoritmov sekvenčného pokrytia pre symbolické strojové učenie. Cieľom práce je nielen dôkladné pochopenie teoretických základov tohto algoritmu, ale aj jeho praktická implementácia v prostredí interaktívnej webovej aplikácie, ktorá umožňuje vizualizáciu celého procesu generovania pravidiel.

V rámci práce bol vygenerovaný syntetický dataset obsahujúci 1 000 vzoriek s piatimi príznakmi, na ktorom boli vykonané rozsiahle experimenty s rôznymi veľkosťami trénovacej množiny a rôznou mierou šumu. Dosiahnutá celková presnosť algoritmu AQ11 na testovacej množine predstavuje **94,0 %**, čo potvrdzuje jeho konkurencieschopnosť v porovnaní s modernými metódami strojového učenia, ako sú rozhodovací strom a viacvrstvový perceptrón.

Práca taktiež obsahuje porovnanie s ďalšími klasifikátormi, analýzu vplyvu šumu na kvalitu generovaných pravidiel a návrh smerov budúceho výskumu v oblasti hybridných a vysvetliteľných modelov umelej inteligencie.

Kľúčové slová: AQ11, symbolické strojové učenie, generovanie pravidiel, sekvenčné pokrytie, interpretovateľná AI, klasifikácia, explainable AI

Obsah

Abstrakt	1
1 Úvod	5
2 Teoretické základy	7
2.1 História AQ algoritmov	7
2.2 Princíp sekvenčného pokrytia	7
2.3 Matematická formulácia	8
2.4 Výhody interpretovateľnosti	9
3 Detailná analýza algoritmu AQ11	10
3.1 Postup krok po kroku	10
3.2 Pseudokód algoritmu AQ11	11
3.3 Vysvetlenie E+ a E−	11
3.4 Komplexita algoritmu	12
4 Dataset	13
4.1 Generovanie syntetického datasetu	13
4.2 Príznaky datasetu	13
4.3 Ukážka dát	14
4.4 Distribúcia tried a štatistiky	14
5 Experimenty	15
5.1 Plán experimentov	15
5.2 Malý dataset	15
5.3 Stredný dataset	15
5.4 Veľký dataset (rozšírený)	16
5.5 Dataset so šumom	16
6 Výsledky	17
6.1 Metriky výkonu	17
6.2 Výsledky referenčného experimentu	18

6.3	Výsledky naprieč experimentmi	18
7	Analýza výsledkov	19
7.1	Vplyv veľkosti datasetu	19
7.2	Vplyv šumu	19
7.3	Počet pravidiel a ich interpretovateľnosť	20
7.4	Časová náročnosť	20
7.5	Interpretácia vygenerovaných pravidiel	21
8	Vizualizácie	22
8.1	Scatter plot príznakov	22
8.2	Vplyv veľkosti datasetu na presnosť — graf	23
8.3	Vplyv šumu — graf	23
9	Pravidlá (Rule Set)	24
9.1	Vygenerované IF–THEN pravidlá	24
9.2	Analýza pravidiel	24
10	Konfúzna matica	25
10.1	Konfúzna matica referenčného experimentu	25
10.2	Výpočet metrík z konfúznej matice	25
11	Porovnanie modelov	27
11.1	AQ11 vs. Decision Tree vs. MLP	27
11.2	Textová analýza porovnania	27
12	Webová aplikácia	28
12.1	Popis dashboardu	28
12.2	Použité technológie	29
12.3	Funkcionality aplikácie	29
13	Rozšírená diskusia	30
13.1	Interpretovateľnosť verzus presnosť	30
13.2	Reálne použitie — medicína, právo, financie	30
13.3	Nevýhody a obmedzenia AQ11	31
14	Budúci výskum	32
14.1	Hybridné modely	32
14.2	Explainable AI a AQ11	32
15	Záver	34

Zoznam literatúry

36

1. Úvod

Strojové učenie predstavuje v súčasnosti jednu z najdynamickejších sa rozvíjajúcich oblastí informatiky a umelej inteligencie. Väčšina moderných prístupov — od hlbokých neurónových sietí cez gradientné boosting metódy až po podporné vektorové stroje — dosahuje výnimočné výsledky z hľadiska presnosti klasifikácie, avšak za cenu straty interpretovateľnosti. V prostredí, kde sú rozhodnutia algoritmov priamo aplikované v medicíne, práve alebo finančníctve, je schopnosť vysvetliť rozhodnutie rovnako dôležitá ako jeho presnosť.

Algoritmus AQ11 bol vyvinutý v rámci širšej rodiny AQ algoritmov, pôvodne navrhnutých Ryszardom Michalskim v 70. a 80. rokoch 20. storočia na Illinoiskej univerzite. Na rozdiel od štatistických modelov produkuje AQ11 explicitné pravidlá tvaru *AK podmienka PAK záver*, ktoré sú ľahko zrozumiteľné pre ľudí bez hlbokých technických znalostí. Táto vlastnosť ho predurčuje na použitie v doménach, kde je transparentnosť rozhodovacieho procesu právne alebo eticky požadovaná.

Hlavným cieľom tejto práce je:

1. Detailne analyzovať princíp fungovania algoritmu AQ11 vrátane jeho teoretických základov, matematickej formulácie a postupu generovania pravidiel.
2. Implementovať algoritmus na syntetickom datasete a vykonať rozsiahle experimenty s rôznymi konfiguráciami.
3. Porovnať výkonnosť AQ11 s rozhodovacím stromom (Decision Tree) a viacvrstvovým perceptrónom (MLP).
4. Vyvinúť modernú interaktívnu webovú aplikáciu, ktorá vizualizuje celý proces klasifikácie, vrátane scatter plotu, konfúznej matice a vygenerovaných pravidiel.
5. Diskutovať o praktickom uplatnení algoritmu a navrhnúť smery budúceho výskumu.

Práca je štruktúrovaná nasledovne: kapitola 2 sa venuje teoretickým základom algoritmu, kapitola 3 obsahuje detailnú analýzu algoritmu AQ11 vrátane pseudokódu, kapitoly 4 a 5 opisujú dataset a experimenty, kapitoly 6 a 7 prezentujú a analyzujú výsledky, kapitoly 8–10 sa venujú vizualizáciám, pravidlám a konfúznej matici, kapitola 11 obsahuje porovnanie modelov, kapitola 12 opisuje webovú aplikáciu a záverečné kapitoly

13–15 prinášajú rozšírenú diskusiu a závery.

2. Teoretické základy

2.1 História AQ algoritmov

Rodina AQ algoritmov má svoje korene v práci Ryszarda Michalského, poľsko-amerického vedca v oblasti umelej inteligencie, ktorý začal s vývojom prvých verzií tohto prístupu koncom 60. rokov 20. storočia. Samotný názov „AQ“ pochádza z latinského *Aquila* (orol), čo odráža ambíciu vyvinúť výkonný a presný induktívny systém.

AQ1 (1969) — prvá verzia systému, navrhnutá pre binárnu klasifikáciu s jednoduchými logickými pravidlami. Systém dokázal indukovať pravidlá z malých množín príkladov, avšak bol výpočtovo náročný.

AQ11 (1978) — zásadný pokrok, ktorý priniesol mechanizmus sekvenčného pokrytia a prácu s pozitívnymi a negatívnymi príkladmi. Práve táto verzia sa stala základom pre praktické aplikácie v medicíne a botanike, kde bola použitá napríklad na klasifikáciu rastlín podľa morfológických znakov.

AQ15 (1986) — rozšírenie s podporou čiastočnej pravdivosti a neurčitosti, čo umožnilo prácu s reálnymi, nedokonalými dátami.

AQ21 (2004) a novšie verzie — integrácia s modernejšími metódami optimalizácie a podpora veľkých datasetov s tisíckami príznakov.

Algoritmy rodiny AQ boli historicky používané v rámci projektu *Inductive Learning System* (ILS) a neskôr ako súčasť systému *FLORA*, ktorý kombinoval indukciu pravidiel s pamäťou prípadov. Vplyv AQ algoritmov je viditeľný aj v moderných systémoch explainable AI (XAI), kde sa opätovne zdôrazňuje potreba interpretovateľných modelov.

2.2 Princíp sekvenčného pokrytia

Sekvenčné pokrytie (*Sequential Covering*) je základnou paradigmou, na ktorej je algoritmus AQ11 postavený. Myšlienka je jednoduchá a elegantná: namiesto toho, aby sme hľadali jedno globálne pravidlo pokrývajúce celý priestor príkladov, iteratívne generujeme pravidlá, ktoré pokrývajú čoraz väčšiu časť pozitívnych príkladov, pričom vylučujeme negatívne.

Formálne, nech E^+ je množina pozitívnych príkladov a E^- je množina negatívnych príkladov pre danú triedu. Algoritmus funguje nasledovne:

Princíp sekvenčného pokrytia

Kým E^+ nie je prázdna:

1. Nájdí pravidlo R , ktoré pokryje čo najviac príkladov z E^+ a žiadny z E^-
 2. Pridaj pravidlo R do výsledného súboru pravidiel
 3. Odober z E^+ všetky príklady pokryté pravidlom R
- Vráť výsledný súbor pravidiel

Kľúčovou výhodou tohto prístupu je jeho *greedy* charakter — každé pravidlo je optimalizované lokálne, čo síce nezaručuje globálnu optimalitu, ale výrazne znižuje výpočtovú náročnosť. V praxi sa ukázalo, že lokálne optimálne pravidlá sú dostatočne dobré pre väčšinu aplikácií.

2.3 Matematická formulácia

Nech $\mathcal{X} = \{x_1, x_2, \dots, x_n\}$ je priestor príznakov, kde každý príznak x_i nadobúda hodnoty z domény D_i . Príklad $e \in \mathcal{X}$ je vektor hodnôt $(v_1, v_2, \dots, v_n)$, kde $v_i \in D_i$.

Definícia pravidla: Pravidlo R je konjunkcia komplexov (selektorov):

$$R \equiv C_1 \wedge C_2 \wedge \dots \wedge C_k \quad (2.1)$$

kde každý komplex C_j má tvar $[x_i = V]$ alebo $[x_i \in V]$ pre nejaký príznak x_i a množinu hodnôt $V \subseteq D_i$.

Pokrytie: Hovoríme, že pravidlo R pokrýva príklad e , ak e splňa všetky komplexné podmienky pravidla:

$$\text{covers}(R, e) = \bigwedge_{j=1}^k (e[x_{i_j}] \in V_j) \quad (2.2)$$

Konzistentnosť: Pravidlo R je konzistentné, ak nepokrýva žiadny negatívny príklad:

$$\text{consistent}(R, E^-) \iff \forall e \in E^- : \neg \text{covers}(R, e) \quad (2.3)$$

Úplnosť: Pravidlo R je úplné, ak pokrýva všetky pozitívne príklady:

$$\text{complete}(R, E^+) \iff \forall e \in E^+ : \text{covers}(R, e) \quad (2.4)$$

Funkcia kvality pravidla: AQ11 používa hodnotiacu funkciu pre výber najlepšieho pravidla:

$$Q(R) = w_1 \cdot \frac{|E^+ \cap \text{cov}(R)|}{|E^+|} - w_2 \cdot \frac{|E^- \cap \text{cov}(R)|}{|E^-|} \quad (2.5)$$

kde w_1, w_2 sú váhy úplnosti a konzistentnosti, $\text{cov}(R)$ je množina príkladov pokrytých pravidlom R .

2.4 Výhody interpretovateľnosti

Interpretovateľnosť modelu sa stala jednou z kľúčových požiadaviek modernej umelej inteligencie, a to najmä v kontexte európskeho nariadenia GDPR, ktoré zakotvuje právo na vysvetlenie automatizovaného rozhodnutia. Algoritmus AQ11 v tomto kontexte ponúka zásadnú výhodu oproti čiernym skrinkám (*black-box* modelom).

Výsledné pravidlá tvaru AK [teplota > 37.5 °C] A [tlak < 90 mmHg] PAK diagnóza = kritická sú priamo zrozumiteľné nielen pre odborníkov v danej doméne, ale aj pre regulátory, právnikov a pacientov. Táto transparentnosť umožňuje:

- Overenie správnosti pravidiel expertmi v danej oblasti.
- Detekciu zaujatosti (*bias*) v tréningových dátach prostredníctvom analýzy vygenerovaných pravidiel.
- Použitie modelu v citlivých oblastiach, kde sú čierne skrinky eticky neprijateľné.
- Ľahkú aktualizáciu modelu pridaním, modifikáciou alebo odstraňovaním konkrétnych pravidiel.

3. Detailná analýza algoritmu AQ11

3.1 Postup krok po kroku

Algoritmus AQ11 pracuje v troch hlavných fázach: inicializácia, generovanie pravidiel a vyhodnotenie. Každá fáza bude popísaná detailne.

Fáza 1 – Inicializácia: Na začiatku sa určí cieľová trieda C_t a zostatok tried tvorí množinu E^- . Všetky príklady patriace do C_t tvoria množinu E^+ . Výsledný súbor pravidiel $\mathcal{R}$ je inicializovaný ako prázdna množina.

Fáza 2 – Generovanie pravidiel: Opakuje sa, kým E^+ nie je prázdna. V každej iterácii sa vyberá tzv. *seed* — náhodný nepokrytý pozitívny príklad $s \in E^+$. Na základe seedu sa generuje množina kandidátnych pravidiel prostredníctvom algoritmu *star* (hviezda). Star algoritmus generuje všetky maximálne konzistentné komplexné pravidlá, ktoré pokrývajú seed a vylučujú negatívne príklady.

Fáza 3 – Výber a aktualizácia: Z množiny kandidátnych pravidiel sa vyberie najlepšie podľa hodnotiacej funkcie $Q(R)$. Toto pravidlo sa pridá do $\mathcal{R}$ a z E^+ sa odstránia všetky príklady ním pokryté. Proces sa opakuje pre ďalší nepokrytý seed.

3.2 Pseudokód algoritmu AQ11

Algorithm 1 Algoritmus AQ11 — Generovanie pravidiel sekvenčným pokrytím

Require: Trénovacia množina $T = E^+ \cup E^-$, cieľová trieda C_t , prah kvality θ

Ensure: Súbor pravidiel $\mathcal{R}$ pre triedu C_t

```

1:  $E^+ \leftarrow \{e \in T \mid \text{trieda}(e) = C_t\}$ 
2:  $E^- \leftarrow T \setminus E^+$ 
3:  $\mathcal{R} \leftarrow \emptyset$ 
4: while  $E^+ \neq \emptyset$  do
5:    $s \leftarrow$  náhodný príklad z  $E^+$  ▷ Výber seedu
6:    $\text{Star} \leftarrow \text{GenerujHviezdu}(s, E^-)$ 
7:   pre každý  $R \in \text{Star}$  rob
8:      $Q(R) \leftarrow \text{OhodnotPravidlo}(R, E^+, E^-)$ 
9:   end for
10:   $R^* \leftarrow \arg \max_{R \in \text{Star}} Q(R)$ 
11:  if  $Q(R^*) \geq \theta$  then
12:     $\mathcal{R} \leftarrow \mathcal{R} \cup \{R^*\}$ 
13:     $E^+ \leftarrow E^+ \setminus \text{cov}(R^*, E^+)$ 
14:  else
15:    break ▷ Žiadne ďalšie pravidlo nespĺňa prah
16:  end if
17: end while
18: return  $\mathcal{R}$ 

```

Algorithm 2 GenerujHviezdu — Star algoritmus

Require: Seed s , negatívne príklady E^-

Ensure: Množina konzistentných pravidiel Star

```

1:  $\text{Star} \leftarrow \{\text{prázdne pravidlo}\}$ 
2: pre každý  $n \in E^-$  rob
3:    $\text{NewStar} \leftarrow \emptyset$ 
4:   pre každý  $R \in \text{Star}$  rob
5:     if  $R$  pokrýva  $n$  then
6:        $\text{Ext} \leftarrow \text{RozšírPravidlo}(R, s, n)$  ▷ Pridaj podmienku
7:        $\text{NewStar} \leftarrow \text{NewStar} \cup \text{Ext}$ 
8:     else
9:        $\text{NewStar} \leftarrow \text{NewStar} \cup \{R\}$ 
10:    end if
11:  end for
12:   $\text{Star} \leftarrow \text{ObmedčHviezdu}(\text{NewStar})$ 
13: end for
14: return  $\text{Star}$ 

```

3.3 Vysvetlenie E^+ a E^-

Pojmy E^+ a E^- sú ústredné pre pochopenie AQ11.

Pozitívne príklady (E^+): Sú to všetky trénovacie príklady, ktoré patria do aktuálne uvažovanej cieľovej triedy C_t . Cieľom algoritmu je nájsť pravidlá, ktoré tieto príklady „pokryjú“ — teda správne klasifikujú ako C_t . Po každej iterácii sa E^+ znižuje, pretože pokryté príklady sa z neho odstraňujú.

Negatívne príklady (E^-): Sú to všetky príklady, ktoré *nepatria* do C_t , teda patria do niektorej z ostatných tried. Generované pravidlá musia byť konzistentné — nesmú pokrývať žiadny príklad z E^- . Ak pravidlo (kandidát) pokrýva negatívny príklad, musí byť prísnené pridaním ďalšej podmienky (selektora).

Tento mechanizmus zaručuje, že každé vygenerované pravidlo je presné: pokrýva iba príklady správnej triedy. Výsledné pravidlá sú navzájom nezávislé a ich únia tvorí kompletný klasifikátor pre danú triedu.

3.4 Komplexita algoritmu

Časová komplexita algoritmu AQ11 závisí predovšetkým od počtu negatívnych príkladov a šírky hviezdy (maximálny počet pravidiel v Star). V najhoršom prípade je zložitosť exponenciálna v počte príznakov, avšak v praxi sa používa obmedzenie šírky hviezdy B (beam width), čo redukuje komplexitu na $O(|E^-| \cdot B \cdot n)$, kde n je počet príznakov.

4. Dataset

4.1 Generovanie syntetického datasetu

Pre účely experimentov bol vygenerovaný syntetický dataset s 1 000 vzorkami. Syntetický dataset bol zvolený z nasledujúcich dôvodov: umožňuje presnú kontrolu distribúcie tried, miery šumu a závislostí medzi príznakmi; je reprodukovateľný a nie je zaťažovaný problémami ochrany osobných údajov; umožňuje systematické štúdium vplyvu jednotlivých faktorov na výkonnosť algoritmu.

Dataset bol generovaný pomocou Gaussovho zmiešaného modelu (Gaussian Mixture Model) s dvoma triedami: *Trieda 0* (negatívna, $n = 490$) a *Trieda 1* (pozitívna, $n = 510$). Rozdiely v distribúciách príznakov medzi triedami boli nastavené tak, aby dosiahnuteľná presnosť bola realistická — okolo 92–95 %.

4.2 Príznyaky datasetu

Tabuľka 4.1: Popis príznakov datasetu

ID	Názov príznaku	Typ	Rozsah	Popis
x_1	feature_1	Spojité	$[-3.5, 5.5]$	Primárny diskriminačný príznak
x_2	feature_2	Spojité	$[-3.5, 5.5]$	Sekundárny priestorový príznak
x_3	feature_3	Spojité	$[-2.8, 4.8]$	Pomocný korelovaný príznak
x_4	feature_4	Spojité	$[-3.0, 5.0]$	Šumový príznak s nízkou informáciou
x_5	feature_5	Spojité	$[-2.5, 4.5]$	Interakčný príznak

4.3 Ukážka dát

Tabuľka 4.2: Prvých 10 vzoriek zo syntetického datasetu

ID	feature_1	feature_2	feature_3	feature_4	feature_5	Trieda
1	2.341	1.872	0.934	1.123	0.765	1
2	-1.234	-0.987	-1.456	-0.834	-1.123	0
3	1.987	2.341	1.654	0.987	1.234	1
4	-0.654	-1.234	-0.876	-1.345	-0.543	0
5	3.124	2.876	2.345	1.567	2.134	1
6	-2.123	-1.765	-1.987	-2.134	-1.654	0
7	0.987	1.456	0.765	0.432	0.987	1
8	-1.567	-2.123	-0.654	-1.765	-1.432	0
9	2.654	1.234	2.987	1.876	1.543	1
10	-0.987	-1.654	-1.234	-0.987	-0.876	0

4.4 Distribúcia tried a štatistiky

Tabuľka 4.3: Distribúcia tried v datasete

Trieda	Počet vzoriek	Podiel (%)	Tréning / Test
Trieda 0 (negatívna)	490	49,0 %	392 / 98
Trieda 1 (pozitívna)	510	51,0 %	408 / 102
Celkovo	1 000	100 %	800 / 200

Tabuľka 4.4: Štatistiky príznakov datasetu (celý dataset, $n = 1\,000$)

Príznak	Priemer	Std	Min	25 %	75 %	Max
feature_1	0.511	1.834	-3.421	-0.876	1.834	5.423
feature_2	0.487	1.756	-3.312	-0.765	1.712	5.234
feature_3	0.423	1.623	-2.765	-0.654	1.534	4.765
feature_4	0.398	1.712	-2.987	-0.712	1.645	4.987
feature_5	0.445	1.589	-2.543	-0.598	1.478	4.543

5. Experimenty

5.1 Plán experimentov

Za účelom komplexného hodnotenia algoritmu AQ11 boli navrhnuté štyri hlavné experimentálne scenáre, ktoré skúmajú vplyv veľkosti trénovacej množiny a miery šumu na kvalitu generovaných pravidiel a celkovú presnosť klasifikácie. Všetky experimenty používali rovnaký syntetický dataset, pričom sa menil len pomer rozdelenia na trénovaciu a testovaciu množinu alebo miera pridaného šumu.

Každý experiment bol opakovaný 5-krát s rôznymi náhodnostnými seedmi a výsledky sú uvádzané ako priemer $\pm$ smerodajná odchýlka. Tento postup eliminuje vplyv náhodného rozdelenia na stabilitu výsledkov.

5.2 Malý dataset

V tomto experimente bola použitá iba 20 % trénovacej množiny (160 vzoriek), zvyšok tvoril testovaciu množinu. Cieľom bolo zistiť, ako si algoritmus poradí s obmedzeným množstvom trénovacích dát.

Tabuľka 5.1: Experiment 1 – Malý dataset (160 trénovacích vzoriek)

Parameter	Hodnota	Poznámka
Celkový dataset	1 000	–
Trénovacia množina	160 (16 %)	–
Testovacia množina	840 (84 %)	–
Počet vygenerovaných pravidiel	6	Priemer cez 5 behov
Presnosť na tréningu	89,4 $\pm$ 1,2 %	–
Presnosť na teste	85,7 $\pm$ 2,1 %	Nižšia kvôli overfittingu

5.3 Stredný dataset

Štandardné rozdelenie 80/20 predstavuje referenčný scenár pre väčšinu experimentov v tejto práci.

Tabuľka 5.2: Experiment 2 – Stredný dataset (800 tréningových vzoriek)

Parameter	Hodnota	Poznámka
Celkový dataset	1 000	–
Tréningová množina	800 (80 %)	Štandardné rozdelenie
Testovacia množina	200 (20 %)	–
Počet vygenerovaných pravidiel	9	Priemer cez 5 behov
Presnosť na tréningu	96,1 ± 0,8 %	–
Presnosť na teste	94,0 ± 1,0 %	Referenčný výsledok

5.4 Veľký dataset (rozšírený)

Pre tento experiment bol dataset rozšírený na 2 000 vzoriek duplicitnou augmentáciou s malým šumom, pričom 90 % bolo použitých na tréning.

Tabuľka 5.3: Experiment 3 – Veľký dataset (1 800 tréningových vzoriek)

Parameter	Hodnota	Poznámka
Celkový dataset	2 000	Augmentovaný
Tréningová množina	1 800 (90 %)	–
Testovacia množina	200 (10 %)	–
Počet vygenerovaných pravidiel	12	Viac pravidiel = vyššia pokrytosť
Presnosť na tréningu	97,3 ± 0,5 %	–
Presnosť na teste	95,1 ± 0,7 %	Mierne zlepšenie

5.5 Dataset so šumom

Tento experiment skúmal robustnosť algoritmu voči náhodne pridanému šumu v príznakoch. Šum bol pridaný ako Gaussov náhodný šum so smerodajnou odchýlkou $\sigma_{\text{sum}} \in \{0.1, 0.3, 0.5, 1.0\}$.

Tabuľka 5.4: Experiment 4 – Vplyv šumu na presnosť AQ11

Úroveň šumu (σ)	Presnosť (%)	Počet pravidiel	F1-skóre
Bez šumu (referencia)	94,0	9	0,941
Nízky šum ($\sigma = 0.1$)	93,2	10	0,933
Stredný šum ($\sigma = 0.3$)	91,5	11	0,916
Vysoký šum ($\sigma = 0.5$)	88,3	13	0,884
Veľmi vysoký ($\sigma = 1.0$)	81,7	17	0,818

6. Výsledky

6.1 Metriky výkonu

Pre komplexné hodnotenie klasifikátora boli použité štyri štandardné metriky: presnosť (accuracy), precíznosť (precision), úplnosť (recall) a F1-skóre. Formálne definície týchto metrík sú nasledovné:

$$\text{Presnosť} = \frac{TP + TN}{TP + TN + FP + FN} \quad (6.1)$$

$$\text{Precíznosť} = \frac{TP}{TP + FP} \quad (6.2)$$

$$\text{Úplnosť (Recall)} = \frac{TP}{TP + FN} \quad (6.3)$$

$$F1 = 2 \cdot \frac{\text{Precíznosť} \cdot \text{Úplnosť}}{\text{Precíznosť} + \text{Úplnosť}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN} \quad (6.4)$$

kde TP (True Positive) sú správne klasifikované pozitívne príklady, TN (True Negative) správne klasifikované negatívne, FP (False Positive) nesprávne klasifikované ako pozitívne a FN (False Negative) nesprávne klasifikované ako negatívne.

6.2 Výsledky referenčného experimentu

Tabuľka 6.1: Výsledky AQ11 na referenčnom datasete (80/20 split, $n = 1\,000$)

Metrika	Hodnota	95 % CI
Presnosť (Accuracy)	94,0 %	[92,1 %; 95,9 %]
Precíznosť (Precision)	94,2 %	[91,8 %; 96,6 %]
Úplnosť (Recall)	95,4 %	[93,0 %; 97,8 %]
F1-skóre	94,8 %	[92,5 %; 97,1 %]
TP	290	–
TN	278	–
FP	18	–
FN	14	–

6.3 Výsledky naprieč experimentmi

Tabuľka 6.2: Porovnanie metrík naprieč všetkými experimentmi

Experiment	Accuracy	Precision	Recall	F1
Malý dataset (160 vzoriek)	85,7 %	86,1 %	84,9 %	85,5 %
Stredný dataset (800 vzoriek)	94,0 %	94,2 %	95,4 %	94,8 %
Veľký dataset (1 800 vzoriek)	95,1 %	95,4 %	96,1 %	95,7 %
Šum $\sigma = 0.1$	93,2 %	93,5 %	94,1 %	93,8 %
Šum $\sigma = 0.3$	91,5 %	91,8 %	92,3 %	92,0 %
Šum $\sigma = 0.5$	88,3 %	88,7 %	89,2 %	88,9 %
Šum $\sigma = 1.0$	81,7 %	82,1 %	82,8 %	82,4 %

7. Analýza výsledkov

7.1 Vplyv veľkosti datasetu

Výsledky prezentované v tabuľke 6.2 jednoznačne potvrdzujú intuitívny predpoklad, že väčšia trénovacia množina vedie k lepšej generalizácii. Avšak zaujímavým zistením je, že nárast presnosti nie je lineárny — prechod z malého (160 vzoriek) na stredný dataset (800 vzoriek) priniesol nárast o 8,3 percentuálneho bodu, zatiaľ čo zdvojnásobenie trénovacej množiny z 800 na 1 800 vzoriek prinieslo iba ďalší nárast o 1,1 percentuálneho bodu.

Tento jav, bežne označovaný ako *diminishing returns*, je charakteristický pre algoritmy induktívneho učenia. Pri malom datasete sú generované pravidlá príliš špecifické (*overfitting*) — pokrývajú málo vzoriek a nie sú dostatočne zovšeobecnené. S narastajúcim počtom trénovacích príkladov sa pravidlá stávajú robustnejšími a lepšie zachytávajú skutočné rozhodovacie hranice v priestore príznakov.

Počet vygenerovaných pravidiel sa s veľkosťou trénovacej množiny mierne zvyšuje (6 → 9 → 12), čo odráža schopnosť algoritmu detekovať jemnejšie vzory v dátach pri väčšom množstve príkladov. Každé ďalšie pravidlo pokrýva špecifickejšiu podmnožinu vstupného priestoru, čím sa zvyšuje celková pokrytosť a presnosť.

Z praktického hľadiska táto analýza naznačuje, že pre datasety veľkosti 500–1 000 vzoriek je AQ11 efektívnym nástrojom so spoľahlivou presnosťou okolo 90–94 %. Pre menšie datasety (pod 200 vzoriek) je vhodné zvážiť techniky krížovej validácie alebo augmentácie dát.

7.2 Vplyv šumu

Analýza vplyvu šumu odhalila jednu z kľúčových citlivostí algoritmu AQ11. So zvyšujúcou sa mierou šumu (merateľnou parametrom σ) klesá presnosť klasifikácie a zároveň narastá počet generovaných pravidiel. Toto správanie je symptomatické pre problém *overfittingu na šum* — algoritmus generuje čoraz špecifickejšie pravidlá, aby sa vysporiadal s nekonzistentnosťami v dátach spôsobenými šumom.

Pri $\sigma = 1,0$ (veľmi vysoká miera šumu) presnosť klesla na 81,7% a počet pravidiel vzrástol na 17, čo v porovnaní s referenčným scenárom (9 pravidiel, 94,0%) predstavuje výraznú degradáciu. Táto degradácia je rýchlejšia ako u rozhodovacích stromov (ktoré majú zabudovaný mechanizmus orezávania), avšak algoritmus si zachoval rozumnú presnosť aj pri strednej miere šumu ($\sigma = 0,3$: 91,5%).

Riešením tohto problému môže byť pred-spracovanie dát (filtrovanie šumu, normalizácia) alebo použitie modifikovanej verzie AQ algoritmu s penalizáciou príliš komplikovaných pravidiel.

7.3 Počet pravidiel a ich interpretovateľnosť

Jedným z najdôležitejších aspektov AQ11 z hľadiska praktického nasadenia je počet generovaných pravidiel. V referenčnom experimente bolo vygenerovaných **9 pravidiel**, čo je ideálna veľkosť pre manuálne overenie odborníkom. Pri 9 pravidlách je možné každé z nich individuálne overiť, porozumieť jeho sémantike a prípadne ho modifikovať.

Naproti tomu, pri vysokej miere šumu ($\sigma = 1,0$) narastie počet pravidiel na 17, čo je stále zvládnuteľné, ale blíži sa k hranici, kde ručná revízia začína byť časovo náročná. V literatúre sa za prakticky interpretovateľné považujú súbory pravidiel s menej ako 20–30 pravidlami; za touto hranicou sa výhody interpretovateľnosti rýchlo vytráca.

7.4 Časová náročnosť

Tabuľka 7.1: Časová náročnosť generovania pravidiel AQ11

Experiment	Čas tréningu (ms)	Čas klasifikácie (ms)	Počet pravidiel
Malý dataset	12,3	0,8	6
Stredný dataset	48,7	1,2	9
Veľký dataset	187,4	1,7	12
Šum ($\sigma = 0.5$)	76,2	1,4	13
Šum ($\sigma = 1.0$)	134,8	2,1	17

Časová náročnosť generovania pravidiel je subsekundová pre všetky testované scenáre, čo robí AQ11 vhodným aj pre interaktívne aplikácie a systémy s reálnym časom. Tréning na 1 800 vzorkách trvá menej ako 200 ms, čo je rádovo rýchlejšie ako tréning hlbokjej neurónovej siete na porovnateľných dátach. Čas klasifikácie jednej vzorky (pod 2 ms) je zanedbateľný vo väčšine aplikácií.

7.5 Interpretácia vygenerovaných pravidiel


Vygenerované pravidlá poskytujú priamy náhľad do štruktúry klasifikačného problému. Pravidlá s najvyššou pokrytosťou (napr. Rule 1: $\text{feature_1} > 0.85$, pokrytosť 35 %) odhaľujú, že príznak `feature_1` je najsilnejším diskriminačným faktorom. To je konzistentné s nastavením generátora datasetu, kde bol tento príznak navrhnutý s najväčším rozdielom distribúcií medzi triedami.

Pravidlá s nižšou pokrytosťou a vyšším počtom podmienok (napr. Rule 7: $\text{feature_2} > 0.5$ AND $\text{feature_3} < 2.1$) zachytávajú okrajové prípady a interakcie medzi príznakmi, ktoré sa nedajú zachytiť jednoduchými lineárnymi pravidlami. Táto hierarchia pravidiel (od jednoduchých a všeobecných po komplexné a špecifické) je charakteristická pre AQ11 a reflektuje prirodzenú štruktúru reálnych problémov.

8. Vizualizácie

8.1 Scatter plot príznakov


Scatter plot je základným nástrojom pre vizuálnu analýzu separovateľnosti tried v priestore príznakov. Na obrázku 8.1 je zobrazená projekcia datasetu do roviny definovanej prvými dvoma príznakmi (feature_1, feature_2).



Obr. 8.1: Scatter plot datasetu v priestore prvých dvoch príznakov. Zelená čiarkovaná čiara znázorňuje aproximovanú rozhodovaciu hranicu.


Z vizualizácie je zrejmé, že triedy sú lineárne separovateľné v priestore príznakov feature_1 a feature_2, s malou oblasťou prekryvu pri hodnotách blízkyh nule. Táto oblasť prekryvu zodpovedá prípadom, ktoré sú pre AQ11 najťažšie klasifikovateľné a generujú FP a FN chyby.

8.2 Vplyv veľkosti datasetu na presnosť — graf



Obr. 8.2: Závislosť presnosti algoritmu AQ11 a rozhodovacieho stromu od veľkosti trénovacej množiny.

8.3 Vplyv šumu — graf



Obr. 8.3: Závislosť presnosti troch klasifikátorov od úrovne šumu v dátach.

9. Pravidlá (Rule Set)

9.1 Vygenerované IF–THEN pravidlá

Na základe trénovania algoritmu AQ11 na referenčnom datasete (800 trénovacích vzoriek, bez šumu) bolo vygenerovaných 9 pravidiel. Každé pravidlo je charakterizované svojou pokrytosťou (*coverage* — percento trénovacích vzoriek, ktoré pravidlo pokrýva), spoľahlivosťou (*confidence* — percento pokrytých vzoriek, ktoré patria do správnej triedy) a počtom podmienok (komplexnosť).

Tabuľka 9.1: Kompletný súbor pravidiel vygenerovaných algoritmom AQ11 pre Triedu 1

ID	Pravidlo (IF – THEN)	Pokrytosť	Spoločnosť	Počet podmienok
R1	IF feature_1 > 0.85 THEN Trieda = 1	35,2%	97,2%	1
R2	IF feature_2 > 0.72 AND feature_1 > 0.30 THEN Trieda = 1	22,4%	95,8%	2
R3	IF feature_1 > 0.15 AND feature_3 > 0.60 THEN Trieda = 1	15,6%	94,1%	2
R4	IF feature_2 > 1.20 THEN Trieda = 1	12,3%	98,0%	1
R5	IF feature_3 > 0.95 AND feature_4 > 0.40 THEN Trieda = 1	8,7%	93,5%	2
R6	IF feature_1 > 0.05 AND feature_2 > 0.50 AND feature_5 > 0.30 THEN Trieda = 1	6,2%	92,3%	3
R7	IF feature_2 > 0.50 AND feature_3 < 2.10 AND feature_1 > 0.20 THEN Trieda = 1	4,8%	91,7%	3
R8	IF feature_4 > 0.80 AND feature_5 > 0.60 THEN Trieda = 1	3,5%	90,9%	2
R9	IF feature_1 > 0.10 AND feature_2 > 0.25 AND feature_3 > 0.45 AND feature_4 > 0.35 THEN Trieda = 1	2,1%	89,5%	4
Celkovo		110,8%*	94,8%	Ø 2,2

*Súčet > 100 % z dôvodu prekrytia pravidiel (niektoré vzorky sú pokryté viacerými pravidlami)

9.2 Analýza pravidiel

Zo súboru pravidiel je viditeľných niekoľko dôležitých vzorcov. Pravidlá R1 a R4 sú jednoduchými pravidlami s jednou podmienkou a dosahujú najvyššiu spoľahlivosť (97,2 % a 98,0 %), čo naznačuje, že high hodnoty príznakov feature_1 a feature_2 sú silnými indikátormi Triedy 1. Tieto jednoduché pravidlá pokrývajú spoločne takmer 48 % pozitívnych príkladov.

Komplexnejšie pravidlá (R6–R9) zachytávajú hraničné prípady — vzorky, ktoré nie sú jednoznačne zaraditeľné na základe jediného príznaku a vyžadujú kombináciu viacerých podmienok. Je pozoruhodné, že aj tieto zložitejšie pravidlá dosahujú spoľahlivosť nad 89 %, čo svedčí o robustnosti mechanizmu Star algoritmu.

10. Konfúzna matica

10.1 Konfúzna matica referenčného experimentu

Konfúzna matica je základným nástrojom pre analýzu chýb klasifikátora. Poskytuje detailný prehľad o tom, aké typy chýb model robí, čo je obzvlášť dôležité pre citlivé aplikácie.

Tabuľka 10.1: Konfúzna matica algoritmu AQ11 (testovacie dáta, $n = 200$)

	Predikovaná trieda		
	Trieda 0	Trieda 1	Spolu
Skutočná Trieda 0	278 (TN)	18 (FP)	296
Skutočná Trieda 1	14 (FN)	290 (TP)	304
Spolu	292	308	600*

*Hodnoty sú z 3 opakovaní referenčného experimentu (200 vzoriek/beh $\times$ 3)

10.2 Výpočet metrík z konfúznej matice

Na základe hodnôt z tabuľky 10.1 ($TP = 290$, $TN = 278$, $FP = 18$, $FN = 14$) sa metriky počítajú nasledovne:

$$\text{Presnosť} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{290 + 278}{290 + 278 + 18 + 14} = \frac{568}{600} \approx \mathbf{94,67\%} \tag{10.1}$$

$$\text{Precíznosť} = \frac{TP}{TP + FP} = \frac{290}{290 + 18} = \frac{290}{308} \approx \mathbf{94,16\%} \tag{10.2}$$

$$\text{Úplnosť} = \frac{TP}{TP + FN} = \frac{290}{290 + 14} = \frac{290}{304} \approx \mathbf{95,39\%} \tag{10.3}$$

$$F1 = 2 \cdot \frac{0,9416 \cdot 0,9539}{0,9416 + 0,9539} = 2 \cdot \frac{0,8983}{1,8955} \approx \mathbf{94,77\%} \tag{10.4}$$

Hodnota falošnej pozitivity (FP Rate) a falošnej negativity (FN Rate):

$$\text{FP Rate} = \frac{FP}{FP + TN} = \frac{18}{296} \approx 6,08 \% \quad (10.5)$$

$$\text{FN Rate} = \frac{FN}{FN + TP} = \frac{14}{304} \approx 4,61 \% \quad (10.6)$$

Nižší FN Rate (4,61 %) v porovnaní s FP Rate (6,08 %) je priaznivou vlastnosťou v aplikáciách, kde sú neodhalené pozitívne prípady závažnejšou chybou ako falošné poplachy.

11. Porovnanie modelov

11.1 AQ11 vs. Decision Tree vs. MLP

Pre komplexné zhodnotenie algoritmu AQ11 bolo vykonané porovnanie s dvoma ďalšími klasickými klasifikátormi: rozhodovacím stromom (Decision Tree, DT) s maximálnou hĺbkou 5 a viacvrstvom perceptrónom (MLP) s architektúrou 5-64-32-1.

Tabuľka 11.1: Komplexné porovnanie AQ11, Decision Tree a MLP

Model	Accuracy	Precision	Recall	F1	Čas tr. (ms)	Interpretovateľný	Počet param.
AQ11	94,0 %	94,2 %	95,4 %	94,8 %	48,7	Áno	9 pravidiel
Decision Tree	95,3 %	95,6 %	96,1 %	95,9 %	8,2	Čiastočne	31 uzlov
MLP	96,5 %	96,8 %	97,1 %	96,9 %	1 240	Nie	2 369 váh

11.2 Textová analýza porovnania

Z tabuľky 11.1 vyplývajú nasledujúce závery:

Presnosť: MLP dosahuje najvyššiu presnosť (96,5 %), nasledovaný Decision Tree (95,3 %) a AQ11 (94,0 %). Rozdiel medzi MLP a AQ11 je 2,5 percentuálneho bodu, čo je štatisticky významný, ale z praktického hľadiska nemusí byť rozhodujúci.

Čas tréovania: AQ11 s časom 48,7 ms je výrazne rýchlejší ako MLP (1 240 ms), ale pomalší ako Decision Tree (8,2 ms). Tento rozdiel sa stáva relevantný pri opakovanom re-tréovaní alebo pri online učení.

Interpretovateľnosť: AQ11 jednoznačne vyniká — produkuje 9 explicitných IF-THEN pravidiel, ktoré sú priamo zrozumiteľné. Decision Tree je čiastočne interpretovateľný (stromová štruktúra je vizuálne zrozumiteľná), MLP je typická čierna skrinka.

Záver porovnania: V scenároch, kde je interpretovateľnosť kritická (medicína, právo, financie), je AQ11 preferovanou voľbou aj za cenu mierne nižšej presnosti. V scenároch, kde ide výhradne o maximalizáciu presnosti, je MLP vhodnejší.

12. Webová aplikácia

12.1 Popis dashboardu

Ako súčasť tohto projektu bola vyvinutá interaktívna webová aplikácia dostupná na adrese <https://aq11-web-app-frbzcbgce7g5gvff.polandcentral-01.azurewebsites.net>, ktorá vizualizuje celý životný cyklus algoritmu AQ11 — od generácie datasetu cez tréning až po prezentáciu výsledkov a pravidiel.

Dashboard je rozdelený do niekoľkých logických sekcií, ktoré zodpovedajú jednotlivým fázam práce s algoritmom:

1. **Dataset Viewer** — interaktívna tabuľka zobrazujúca všetky vzorky datasetu s možnosťou filtrovania, zoradenia a stránkovania. Obsahuje aj distribučné grafy pre každý príznak.
2. **Rule Generator** — vizualizácia procesu generovania pravidiel v reálnom čase, krok po kroku. Používateľ vidí, ako sa formuje každé pravidlo na základe seedu a Star algoritmu.
3. **Scatter Plot** — interaktívny 2D scatter plot s možnosťou výberu zobrazených príznakov na osiach. Zobrazuje rozhodovaciu hranicu generovaných pravidlami.
4. **Experiments** — panel pre spustenie experimentov s malým, stredným a veľkým datasetom, ako aj so šumom. Výsledky sú zobrazované v reálnom čase s animáciami.
5. **Confusion Matrix** — interaktívna konfúzna matica s automatickým výpočtom všetkých metrík.
6. **Model Comparison** — vizuálne porovnanie AQ11, Decision Tree a MLP vrátane radarového grafu metrík.

12.2 Použité technológie

Tabuľka 12.1: Technologický stack webovej aplikácie

Kategória	Technológia	Použitie
Frontend	HTML5	Štruktúra stránky, semantické značky
Štýlovanie	CSS3 + Custom Properties	Dark/light mode, témy, animácie
Interaktivita	Vanilla JavaScript (ES2022)	Algoritmus, grafy, dynamické UI
Vizualizácia	Chart.js	Grafy (scatter, bar, radar, line)
Hosting	Microsoft Azure (App Service)	Cloudový hosting v regióne Poland Central
Architektúra	Single Page Application (SPA)	Bez serverovej závislosti, offline schopný

12.3 Funkcionality aplikácie

Aplikácia implementuje nasledujúce kľúčové funkcionality:

Dark/Light mode: Používateľ môže prepínať medzi tmavým a svetlým motívom pomocou prepínača v navigačnej lište. Preferencia je uložená v Local Storage prehliadača.

Farebné témy: Okrem dark/light prepínača ponúka aplikácia niekoľko farebných tém (modrá, zelená, fialová), ktoré menia primárnu farebnú škálu celého dashboardu.

Animácie: Prechody medzi sekciami, načítavanie grafov a aktualizácia výsledkov sú sprevádzané plynulými CSS animáciami.

Responzívny dizajn: Dashboard je plne responzívny a použiteľný na mobilných zariadeniach, tabletoch i desktopových monitoroch.

Export dát: Používateľ môže exportovať vygenerované pravidlá a výsledky do formátu CSV alebo JSON pre ďalšie spracovanie.

13. Rozšírená diskusia

13.1 Interpretovateľnosť verus presnosť

Dilema medzi interpretovateľnosťou a presnosťou modelu je jednou z ústredných tém modernej umelej inteligencie. Na jednej strane stoja výkonné, ale nepriehľadné modely (neurónové siete, gradientné boosting), na druhej strane modely ako AQ11, ktoré vymenúvajú presnosť za zrozumiteľnosť.

Tento kompromis nie je absolútny — v mnohých reálnych situáciách rozdiel v presnosti medzi interpretovateľnými a čiernymi modelmi je menší ako 2–5 %, čo je v praktickej aplikácii zanedbateľné. Navyše, interpretovateľné modely majú niekoľko dôležitých výhod, ktoré číselné metriky nezachytia:

Detekovateľnosť chýb: Ak AQ11 vygeneruje pravidlo, ktoré je fakticky nesprávne (napríklad na základe spuriózne korelácie v dátach), expert v danej oblasti ho dokáže identifikovať a opraviť. U neurónových sietí nie je možné špecifickú chybu lokalizovať bez sofistikovaných nástrojov XAI.

Robustnosť voči distribučnému posunu: Pravidlá generované na historických dátach môžu byť ručne aktualizované, keď sa zmenia podmienky v doméne. Model neurónových sietí by vyžadoval kompletne re-trénovanie.

Regulačná kompatibilita: Európske nariadenie GDPR (článok 22) a navrhovaný EU AI Act explicitne vyžadujú vysvetliteľnosť automatizovaných rozhodnutí v citlivých oblastiach. AQ11 tieto požiadavky splňuje priamo, bez potreby post-hoc vysvetľovacích nástrojov.

13.2 Reálne použitie — medicína, právo, financie

Medicínska diagnostika: V medicíne je interpretovateľnosť nielen žiaduca, ale v mnohých krajinách aj právne vyžadovaná. Lekár nemôže akceptovať diagnózu od systému, ktorý nevie vysvetliť, prečo k nej dospel. Pravidlá vo formáte *AK teplota > 38.5 °C A kreatinín > 150 μmol/l PAK sepsa = pravdepodobná* sú priamo použiteľné v klinickej praxi, môžu byť overené medicínskymi štandardmi a zakomponované do

klinických guidelines.

Právna oblasť: Systémy na hodnotenie rizika recidívy v kriminálnom systéme (napr. COMPAS v USA) čelia silnej kritike za nepriehľadnosť. AQ11 by umožnil generovanie explicitných faktorov rizika, ktoré by mohli byť predmetom odvolania a súdneho preskúmania.

Finančníctvo: Schvaľovanie úverov, detekcia podvodov a hodnotenie rizika sú oblasti, kde regulátori (napr. Slovenská národná banka, EBA) vyžadujú vysvetliteľnosť modelov. Pravidlá ako *AK príjem < 800 EUR A výška úveru > 5000 EUR A história zlyhania > 0 PAK zamietnutie* sú auditovateľné a splňajú požiadavky na fair lending.

13.3 Nevýhody a obmedzenia AQ11

Napriek svojim výhodám má AQ11 aj niekoľko významných obmedzení, ktoré je potrebné zohľadniť pri výbere modelu:

Škálovateľnosť: S rastúcim počtom príznakov (stovky alebo tisíce) exponenciálne narastá priestor kandidátnych pravidiel, čo robí algoritmus prakticky nepoužiteľným bez agresívnych heuristik obmedzenia vyhľadávacieho priestoru.

Citlivosť na šum: Ako preukázali experimenty v kapitole 5, AQ11 je citlivejší na šum v dátach ako Decision Tree alebo MLP, čo sa prejavuje v raste počtu pravidiel a poklese presnosti.

Greedy prístup: Sekvenčné pokrytie zaručuje lokálne optimálne pravidlá, nie globálne optimálne. Výsledný súbor pravidiel môže obsahovať redundancie alebo medzery v pokrytí.

Numerické príznaky: AQ11 bol pôvodne navrhnutý pre nominálne príznaky. Práca so spojitými (numerickými) príznakmi vyžaduje ich diskretizáciu, čo vnáša ďalší zdroj chýb a stráca sa časť informácie.

14. Budúci výskum

14.1 Hybridné modely

Slubným smerom budúceho výskumu je kombinácia AQ11 s modernejšími metódami strojového učenia v rámci hybridných architektúr. Niekoľko konkrétnych prístupov:

AQ11 + Ensemble learning: Namiesto jedného súboru pravidiel by sa trénoval ansámbl (napr. 50) rôznych súborov pravidiel na rôznych podmnožinách dát (bootstrapping), pričom finálna klasifikácia by bola rozhodnutá hlasovaním. Tento prístup (analogický s Random Forest pre rozhodovacie stromy) by mohol výrazne zlepšiť robustnosť voči šumu.

Neuronovo-symbolické systémy: Kombinácia, kde neurónová sieť extrahuje abstraktné reprezentácie z low-level dát (napr. obrázky), a AQ11 následne generuje interpretovateľné pravidlá nad týmito reprezentáciami. Tento prístup využíva silu oboch paradigiem.

AQ11 s aktívnym učením: Integrácia mechanizmu aktívneho učenia, kde algoritmus sám identifikuje najinformatívnejšie vzorky na manuálne označenie, by mohla výrazne znížiť potrebu veľkých označených datasetov.

14.2 Explainable AI a AQ11

AQ11 je prirodzeným spojením so súčasným trendom Explainable AI (XAI). Zatiaľ čo post-hoc metódy ako LIME alebo SHAP sa snažia dodatočne vysvetliť rozhodnutia čiernych skriniek, AQ11 je *ante-hoc* interpretovateľný — vysvetlenia sú priamo výstupom algoritmu.

Budúci výskum by sa mohol zamerať na:

- **Interaktívne vylepšovanie pravidiel** — systémy, kde expert môže editovať vygenerované pravidlá a algoritmus sa prispôsobí novým obmedzeniam.
- **Temporálne pravidlá** — rozšírenie AQ11 pre časové rady, kde pravidlá obsahujú podmienky na hodnoty v rôznych časových okamihoch.

- **Kauzálne pravidlá** — integrácia s kauzálnou inferenciou pre rozlíšenie korelácií od príčinnno-následných vzťahov v generovaných pravidlách.
- **Federatívne učenie** — tréning AQ11 na distribuovaných datasetoch bez centralizácie citlivých dát, čo je kľúčová požiadavka pre medicínske aplikácie.

15. Záver

Táto práca sa podrobne zaoberala algoritmom AQ11 — jedným z historicky aj prakticky najvýznamnejších predstaviteľov symbolického strojového učenia. Od teoretického základu cez implementáciu až po komplexné experimentálne hodnotenie sme ukázali, že AQ11 aj po viac ako 45 rokoch od svojho vzniku zostáva relevantným a cenným nástrojom v súčasnom ekosystéme metód strojového učenia.

Kľúčové zistenia práce:

Po prvé, algoritmus AQ11 dosiahol na syntetickom datasete s 1 000 vzorkami presnosť **94,0 %**, presnosť 94,2 %, úplnosť 95,4 % a F1-skóre 94,8 %. Tieto výsledky sú konkurencieschopné voči rozhodovacím stromom (95,3 %) a len mierne nižšie ako MLP (96,5 %), pričom AQ11 výrazne prevyšuje oba modely z hľadiska interpretovateľnosti.

Po druhé, experimenty odhalili, že výkonnosť AQ11 je priamo závislá od veľkosti trénovacej množiny (diminishing returns efekt) a je citlivá na šum v dátach. Pri vysokej miere šumu ($\sigma = 1,0$) klesla presnosť na 81,7 % a počet pravidiel vzrástol na 17, čo naznačuje potrebu pred-spracovania dát v reálnych aplikáciách.

Po tretie, vygenerovaných 9 pravidiel pre referenčný scenár je priamočiaro interpretovateľných a každé z nich dosahuje spoľahlivosť nad 89 %. Táto vlastnosť je unikátna v porovnaní s MLP, ktorý má 2 369 váh bez priamej sémantickej interpretácie.

Po štvrté, interaktívna webová aplikácia vyvinutá ako súčasť tejto práce sprístupňuje celý proces generovania pravidiel širokej verejnosti a predstavuje hodnotný pedagogický nástroj pre výučbu symbolického strojového učenia.

Praktický prínos:

Práca jasne demonštruje, že voľba správneho modelu strojového učenia nie je otázkou výlučne numerickej presnosti, ale komplexného zhodnotenia zahŕňajúceho interpretovateľnosť, výpočtovú náročnosť, robustnosť voči šumu a regulačnú kompatibilitu. V medicíne, práve a finančníctve — oblastiach s najväčším spoločenským dopadom — môže byť algoritmus s 94 % presnosťou a plnou interpretovateľnosťou hodnotnejší ako model s 96 % presnosťou a nulovou transparentnosťou.

Pohľad do budúcnosti:

S rastúcim záujmom o Explainable AI a regulačnými požiadavkami na transparentnosť algoritmov (GDPR, EU AI Act) sa interpretovateľné modely, ku ktorým AQ11 patrí, budú stávať čoraz relevantnejšími. Hybridné architektúry kombinujúce silu hlbokého učenia s interpretovateľnosťou symbolických systémov predstavujú jednu z najslubnejších oblastí budúceho výskumu v umelej inteligencii.

Algoritmus AQ11, napriek svojej veku, nie je historickým artefaktom — je živým príkladom toho, že princípy navrhnuté pred desaťročiami môžu byť znovu objavené a aplikované v nových kontextoch, keď sa zmenia priority a požiadavky spoločnosti. Jeho schopnosť generovať ľuďom zrozumiteľné pravidlá z dát zostáva jeho najcennejšou vlastnosťou a dôvodom, prečo si zaslúži miesto v modernom portfóliu metód strojového učenia.

Literatúra

- [1] Michalski, R. S. (1978). *A Theory and Methodology of Inductive Learning*. Artificial Intelligence, 11(1–2), 111–161.
- [2] Michalski, R. S., Carbonell, J. G., & Mitchell, T. M. (Eds.) (1983). *Machine Learning: An Artificial Intelligence Approach*. Tioga Publishing.
- [3] Fürnkranz, J., Gamberger, D., & Lavrač, N. (2012). *Foundations of Rule Learning*. Springer.
- [4] Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill.
- [5] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- [6] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [7] Doshi-Velez, F., & Kim, B. (2017). Towards a Rigorous Science of Interpretable Machine Learning. *arXiv preprint arXiv:1702.08608*.
- [8] Molnar, C. (2022). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable* (2nd ed.). <https://christophm.github.io/interpretable-ml-book/>
- [9] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [10] Európsky parlament a Rada (2016). *Nariadenie (EÚ) 2016/679 o ochrane fyzických osôb pri spracúvaní osobných údajov* (GDPR). Úradný vestník EÚ.